


# Erkennung von EKG Anomalien mit Hilfe eines Autoencoders



Ein Autoencoder ist eine spezielle Form von Neurealem Netzwerk. Beispielsweise wird ein Bild einer handgeschriebenen Zahl vom Autoencoder zunächst in ein Bild mit weniger Dimensionen codiert. Anschließend wird das reduzierte Bild wieder decodiert, wobei versucht wird, den Rekonstruktionsfehler zu minimieren.

Dieses Verfahren kann genutzt werden, um Anomalien in EKGs zu erkennen. Dazu wird das Modell nur mit Daten normaler EKGs trainiert, jedoch mit dem kompletten Datensatz getestet. Daraus ergibt sich bei der Rekonstruktion abnormaler EKGs ein größerer Rekonstruktionsfehler. Übersteigt die Größe des Fehlers eine definierte Schwelle, wird das EKG als abnormal kategorisiert.

In [1]:

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

from tensorflow.keras import layers, losses
from sklearn.model_selection import train_test_split
from tensorflow.keras.models import Model
```

In [2]:

```
df = pd.read_csv('Input/ecg.csv', header=None)
df.head()
```

Out[2]:

	0	1	2	3	4	5	6	7	
0	-0.112522	-2.827204	-3.773897	-4.349751	-4.376041	-3.474986	-2.181408	-1.818286	-1.25
1	-1.100878	-3.996840	-4.285843	-4.506579	-4.022377	-3.234368	-1.566126	-0.992258	-0.75
2	-0.567088	-2.593450	-3.874230	-4.584095	-4.187449	-3.151462	-1.742940	-1.490659	-1.18
3	0.490473	-1.914407	-3.616364	-4.318823	-4.268016	-3.881110	-2.993280	-1.671131	-1.33
4	0.800232	-0.874252	-2.384761	-3.973292	-4.338224	-3.802422	-2.534510	-1.783423	-1.59

5 rows × 141 columns

Der Datensatz verfügt über 140 Spalten. Die letzte Spalte enthält die Werte 0 und 1, was für abnormales bzw. normales EKG steht und dient somit als Label.

In [3]:

```
# Separieren von Daten und Labels
data = df.iloc[:, :-1].values
labels = df.iloc[:, -1].values
labels
```

Out[3]:

```
array([1., 1., 1., ..., 0., 0., 0.])
```

In [4]:

```
train_data, test_data, train_labels, test_labels = train_test_split(data, labels, test_si
```

### Normalisierung im Bereich [0-1]

Wir verwenden dafür folgende Formel:

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

In [5]:

```
# Maximum und Minimum des Trainingssets berechnen
min = tf.reduce_min(train_data)
max = tf.reduce_max(train_data)

# Verwenden der Formel (data - min)/(max - min)
train_data = (train_data - min)/(max - min)
test_data = (test_data - min)/(max - min)

# Konvertieren der Daten zu float
train_data = tf.cast(train_data, dtype=tf.float32)
test_data = tf.cast(test_data, dtype=tf.float32)
```

In [6]:

```
# Da die Labels 0 oder 1 sind, können sie zu Booleschen Werten konvertiert werden (true,
train_labels = train_labels.astype(bool)
test_labels = test_labels.astype(bool)

# Separieren der Daten von normalen EKGs von Daten abnormaler EKGs
#Normale EKG-Daten
n_train_data = train_data[train_labels]
n_test_data = test_data[test_labels]


#Abnormale EKG-Daten
an_train_data = train_data[~train_labels]
an_test_data = test_data[~test_labels]

print(n_train_data)
```

```
tf.Tensor(
[[0.57030463 0.46561658 0.29058117 ... 0.48504233 0.4233502 0.47598344]
 [0.48320588 0.28246963 0.16471253 ... 0.567567 0.4677294 0.2692329 ]
 [0.48144642 0.35151404 0.25972766 ... 0.5479421 0.5077544 0.54298663]
 ...
 [0.41039047 0.24164985 0.13120876 ... 0.5277313 0.5654091 0.5023885 ]
 [0.5397748 0.4140786 0.28101394 ... 0.51266515 0.43706053 0.4426865 ]
 [0.29639772 0.15988176 0.18883787 ... 0.53766966 0.545786 0.40826708]],
shape=(2359, 140), dtype=float32)
```


In [7]:

```
# Plot eines normalen EKG
plt.plot(np.arange(140), n_train_data[0])
plt.grid()
plt.title('Normal ECG')
plt.show()
```



In [8]:

```
# Plot eines abnormalen EKG
plt.plot(np.arange(140), an_train_data[0])
plt.grid()
plt.title('Abnormal ECG')
plt.show()
```



In [9]:

```
# Definition des Modells
# Das Modell besteht aus 2 Teilen : 1. Encoder and 2. Decoder

class detector(Model):
    def __init__(self):
        super(detector, self).__init__()
        self.encoder = tf.keras.Sequential([
            layers.Dense(32, activation='relu'),
            layers.Dense(16, activation='relu'),
            layers.Dense(8, activation='relu')
        ])
        self.decoder = tf.keras.Sequential([
            layers.Dense(16, activation='relu'),
            layers.Dense(32, activation='relu'),
            layers.Dense(140, activation='sigmoid')
        ])

    def call(self, x):
        encoded = self.encoder(x)
        decoded = self.decoder(encoded)
        return decoded
```

In [10]:

```
# Kompilieren und Training
autoencoder = detector()
autoencoder.compile(optimizer='adam', loss='mae')
autoencoder.fit(n_train_data, n_train_data, epochs = 20, batch_size=512, validation_data=
```

```
Epoch 1/20
5/5 [=====] - 1s 49ms/step - loss: 0.0591 - val_loss: 0.0564
Epoch 2/20
5/5 [=====] - 0s 5ms/step - loss: 0.0558 - val_loss: 0.0543
Epoch 3/20
5/5 [=====] - 0s 5ms/step - loss: 0.0534 - val_loss: 0.0514
Epoch 4/20
5/5 [=====] - 0s 5ms/step - loss: 0.0500 - val_loss: 0.0472
Epoch 5/20
5/5 [=====] - 0s 5ms/step - loss: 0.0456 - val_loss: 0.0426
Epoch 6/20
5/5 [=====] - 0s 5ms/step - loss: 0.0411 - val_loss: 0.0383
Epoch 7/20
5/5 [=====] - 0s 5ms/step - loss: 0.0370 - val_loss: 0.0344
Epoch 8/20
5/5 [=====] - 0s 5ms/step - loss: 0.0332 - val_loss: 0.0312
Epoch 9/20
5/5 [=====] - 0s 5ms/step - loss: 0.0304 - val_loss: 0.0288
Epoch 10/20
5/5 [=====] - 0s 5ms/step - loss: 0.0282 - val_loss: 0.0269
Epoch 11/20
5/5 [=====] - 0s 5ms/step - loss: 0.0265 - val_loss: 0.0254
Epoch 12/20
5/5 [=====] - 0s 5ms/step - loss: 0.0251 - val_loss: 0.0241
Epoch 13/20
5/5 [=====] - 0s 5ms/step - loss: 0.0239 - val_loss: 0.0231
Epoch 14/20
5/5 [=====] - 0s 5ms/step - loss: 0.0231 - val_loss: 0.0224
Epoch 15/20
5/5 [=====] - 0s 5ms/step - loss: 0.0226 - val_loss: 0.0220
Epoch 16/20
5/5 [=====] - 0s 5ms/step - loss: 0.0221 - val_loss: 0.0215
Epoch 17/20
5/5 [=====] - 0s 5ms/step - loss: 0.0217 - val_loss: 0.0211
Epoch 18/20
5/5 [=====] - 0s 5ms/step - loss: 0.0212 - val_loss: 0.0207
Epoch 19/20
5/5 [=====] - 0s 5ms/step - loss: 0.0209 - val_loss: 0.0205
Epoch 20/20
5/5 [=====] - 0s 5ms/step - loss: 0.0207 - val_loss: 0.0203
```


Out[10]:

<keras.callbacks.History at 0x1c917dfbdf0>


In [11]:

```
# Definition einer Funktion zum Plot des originalen EKG und seiner Rekonstruktion inklusi
def plot(data, n):
    enc_img = autoencoder.encoder(data)
    dec_img = autoencoder.decoder(enc_img)
    plt.plot(data[n], 'b')
    plt.plot(dec_img[n], 'r')
    plt.fill_between(np.arange(140), data[n], dec_img[n], color = 'lightcoral')
    plt.legend(labels=['Input', 'Reconstruction', 'Error'])
    plt.show()

plot(n_test_data, 0)
plot(an_test_data, 0)
```







In [12]:

```
# Festlegen des Schwellenwerts für den Fehler
reconstructed = autoencoder(n_train_data)
train_loss = losses.mae(reconstructed, n_train_data)
t = np.mean(train_loss) + np.std(train_loss) # Schwelle als Standardabweichung vom Mittelwert
def prediction(model, data, threshold):
    rec = model(data)
    loss = losses.mae(rec, data)
    return tf.math.less(loss, threshold)
print(t)
```

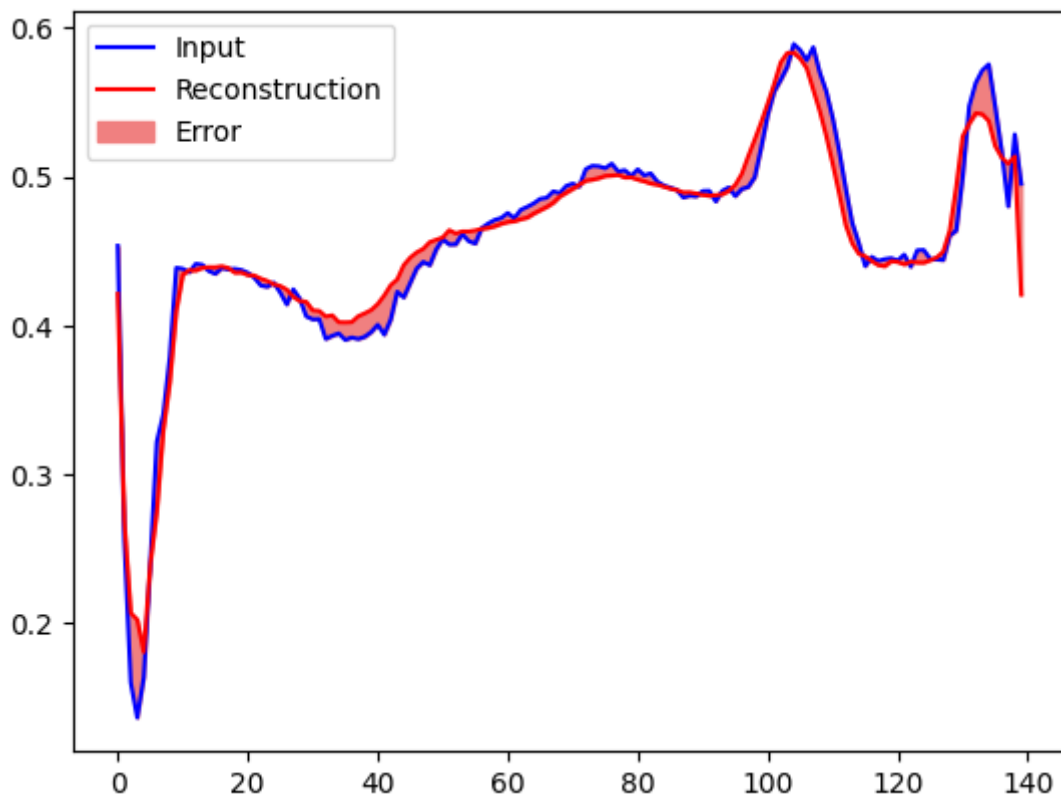

0.032914322

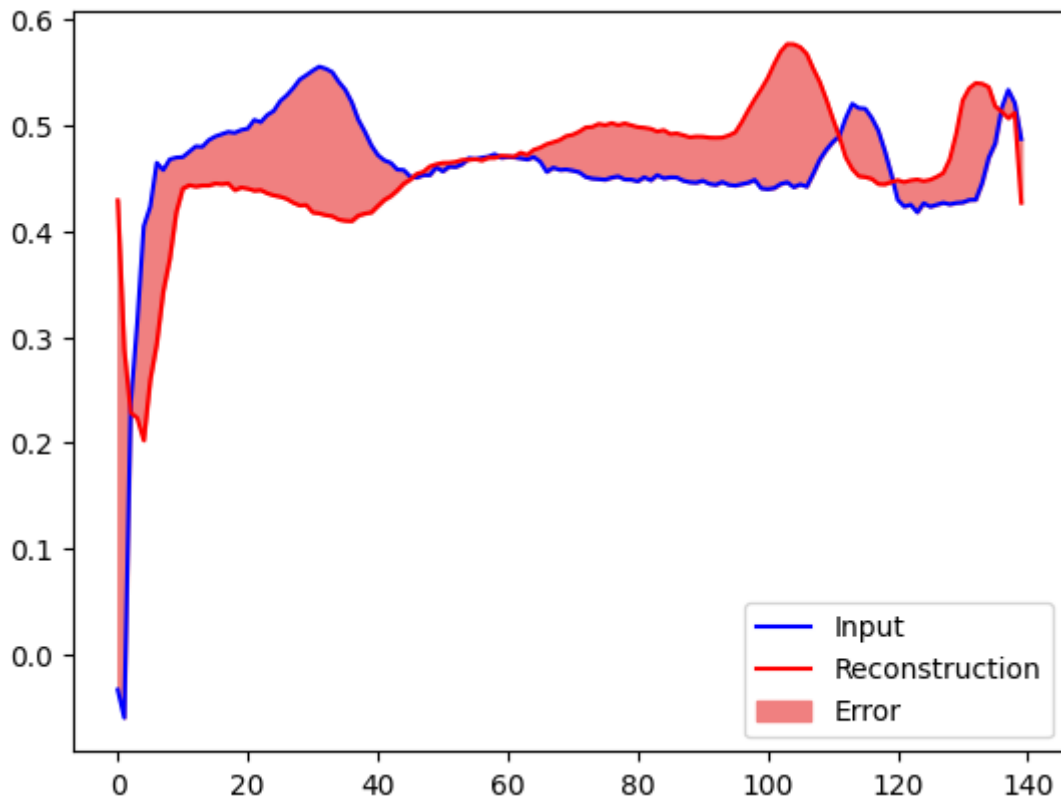
```
pred = prediction(autoencoder, n_test_data, t)
print(pred)
```

1)

In [14]:

```
# Darstellung weiterer Ergebnisse  
plot(n_test_data, 0)  
plot(n_test_data, 1)  
plot(n_test_data, 3)
```





Quellen: <https://www.kaggle.com/code/devavratatripathy/ecg-anomaly-detection-using-autoencoders>  
(<https://www.kaggle.com/code/devavratatripathy/ecg-anomaly-detection-using-autoencoders>).